

Universidad Nacional Autonoma de Mexico
Facultad de Estudios Superiores Acatlán

Relaciones Interpersonales MAC

Documentacion del Proyecto: Modelo de Datos y KPIs

MINERIA DE DATOS

Integrantes del equipo

Alvarado Martinez Miguel Eduardo
Bustos Antonio José Arturo
Estrada Romero Meliza Edith
Soria Cabrera Andrés
Sosa Pérez Dariana Montserrat

22 de marzo de 2026

Índice

1. Justificacion del uso del modelo de datos aplicado (Copo de Nieve)	2
2. Diseno del modelo de datos aplicado	5
3. KPIs propuestos	5
4. Metodologia de limpieza de datos con Python	6

1. Justificacion del uso del modelo de datos aplicado (Copo de Nieve)

El modelo implementado en la base de datos corresponde a un **Copo de Nieve**. Este enfoque parte de una tabla central y descompone la informacion en entidades relacionadas por llaves foraneas. En este proyecto, el eje conceptual son las relaciones interpersonales de estudiantes de la carrera MAC. Por ello, la tabla **relaciones_intepersonales** opera como nodo de integracion, mientras que los bloques tematicos se distribuyen en tablas especializadas (vinculacion afectiva, sociabilidad, estilo de vida, colaboracion y estilo de comunicacion).

Este enfoque se justifica por las siguientes razones:

- **Normalizacion de la informacion:** evita redundancia al separar variables por dominio conceptual.
- **Integridad referencial:** las llaves foraneas garantizan consistencia entre cada bloque de variables.
- **Facilidad de mantenimiento:** se pueden ajustar dominios o reglas por tabla sin afectar todo el modelo.
- **Escalabilidad analitica:** permite agregar nuevas dimensiones (por ejemplo, contexto academico o emocional) sin rediseñar por completo la estructura.
- **Compatibilidad con analisis por tema:** cada tabla representa un componente interpretable de las relaciones interpersonales.

Aunque un modelo Estrella simplifica algunas consultas, en este caso el Copo de Nieve es preferible porque el cuestionario tiene *subconstructos* claramente diferenciados y con reglas de validacion propias.

Diagramas de la base de datos

Los siguientes diagramas representan visualmente la estructura del modelo relacional implementado:




Figura 1: Diagrama general del modelo de datos (version RI).




Figura 2: Diagrama alternativo del modelo de relaciones interpersonales (v1).

2. Diseno del modelo de datos aplicado

El diseno busca cubrir, en esta primera etapa, el mayor espectro de variables disponibles en el formulario de Relaciones Interpersonales. La estructura se organiza en una tabla central y cinco tablas de soporte tematico, donde se catalogan los atributos con base en su funcion analitica.

Como alcance inicial, se priorizo el procesamiento y modelado del formulario base de Relaciones Interpersonales. El objetivo posterior es extender la misma logica de modelado al resto de formularios del proyecto para construir una vista integrada de los factores academicos, sociales y personales.

Tabla central

- relaciones_intepersonales:
 - PK: num_cuenta
 - FKs:
 - vinculacionAfectiva
 - perfilSocial
 - estiloVida
 - colaboracion
 - comunicacionIntepersonal

Tablas de soporte (dimensiones tematicas)

Tabla	Variables principales
vinculacion_afectiva	confianzaInterpersonal, noviazgo, tiempoSoltero
sociabilidad	habilidadSocial, amigos, energiaInterpersonal
estilo_vida	enfoque, tiempoLibre
colaboracion	colaborativo, integracion, participacion
estilo_comunicacion	comunicacion, inciativaInteraccional

3. KPIs propuestos

A continuacion se definen KPIs iniciales para monitorear el estado de las relaciones interpersonales dentro de la muestra. En cada indicador se especifica que variable resume y por que aporta valor al analisis:

1. **Indice promedio de habilidad social:** promedio de `habilidadSocial`. *Razon:* resume la autopercepcion de competencias para relacionarse y funciona como indicador base del perfil socioemocional del grupo.

2. **Porcentaje de estudiantes con red externa:** porcentaje con `amigos` = 1. *Razon:* permite estimar el alcance de la red social fuera del nucleo inmediato y detectar posibles casos de aislamiento.
3. **Tasa de vinculacion afectiva actual:** porcentaje con `noviazgo` = 1. *Razon:* aporta contexto sobre la estructura afectiva de la muestra y ayuda a interpretar dinamicas de apoyo emocional.
4. **Tiempo promedio de solteria:** media de `tiempoSoltero`. *Razon:* complementa la tasa de noviazgo con una medida temporal que permite identificar diferencias entre cohortes o generaciones.
5. **Indice de comunicacion directa:** porcentaje con `comunicacion` = 1. *Razon:* mide la preferencia por formas de interaccion directas, relevantes para colaboracion, acompañamiento y resolucion de conflictos.
6. **Indice de colaboracion academica:** porcentaje con `colaborativo` = 1. *Razon:* refleja disposicion al trabajo en equipo, variable clave para estrategias de aprendizaje colaborativo en la carrera.
7. **Nivel de participacion activa:** porcentaje con `participacion` = 2. *Razon:* identifica la proporcion de estudiantes con mayor involucramiento social, util para planear actividades de integracion.
8. **Indice promedio de integracion en MAC:** promedio de `integracion`. *Razon:* evalua el sentido de pertenencia al entorno academico y permite monitorear cambios en cohesion comunitaria.
9. **Indice promedio de energia interpersonal:** promedio de `energiaInterpersonal`. *Razon:* captura el nivel de iniciativa social percibida y ayuda a segmentar perfiles de interaccion.
10. **Indice compuesto de vinculacion social:** promedio normalizado de `habilidadSocial`, `integracion` y `energiaInterpersonal`. *Razon:* sintetiza tres dimensiones complementarias en una sola metrica para seguimiento global y comparaciones entre periodos.

Nota metodologica

Como siguiente iteracion, cada KPI se documentara con: formula SQL exacta, umbrales objetivo y visualizacion recomendada para dashboard.

4. Metodologia de limpieza de datos con Python

La limpieza del cuestionario se implemento en Python con un flujo reproducible y parametrizable. El proceso principal se encuentra en `python/limpieza_relaciones_interpersonales.py` y su configuracion en `python/relaciones_config.json`.

Objetivo de la limpieza

El objetivo fue transformar respuestas heterogeneas (texto libre, escalas, respuestas binarias y valores mixtos) en un dataset consistente para analisis y carga en base de datos, respetando las restricciones definidas en SQL.

Arquitectura del pipeline

La metodologia se divide en cinco etapas:

1. **Carga y configuracion:** lectura del CSV fuente y carga de parametros desde JSON.
2. **Normalizacion base:** estandarizacion de texto (minusculas, recorte de espacios y formato uniforme).
3. **Limpieza por tipo de variable:** aplicacion de funciones especificas por columna (escalas, binarios, tiempo y texto libre).
4. **Refinamiento semantico con spaCy:** segunda pasada para aproximar la intencion de las respuestas abiertas a conceptos canonicos.
5. **Salida reproducible:** exportacion del dataset limpio en `RelacionesPersonales(limpio).csv`.

Componentes tecnicos utilizados

- **pandas:** lectura/escritura CSV, transformaciones columnares y conversion de tipos.
- **spaCy (es_core_news_md):** tokenizacion, lematizacion y similitud semantica.
- **regex:** extraccion de patrones numericos para variables como `tiempoSoltero`.
- **JSON de configuracion:** desacopla reglas de codigo para facilitar mantenimiento.

Limpieza estructurada por dominios

El proceso aplica reglas distintas segun el tipo de dato:

- **Variables en escala (1–5):** `habilidadSocial`, `integracion`, `energiaInterpersonal`.
- **Variables binarias (0/1):** `amigos`, `noviazgo`, `enfoque`, `colaborativo`, `comunicacion`.
- **Variable temporal discreta:** `tiempoSoltero` (conversion a entero no negativo).
- **Variable ordinal (0–2):** `participacion`.
- **Texto abierto:** `confianzaInterpersonal`, `tiempoLibre`, `inciativaInteraccional`.

Limpieza de texto libre

Para texto abierto se implemento un doble mecanismo:

1. **Limpieza lematizada:** se conservan lemas utiles y se eliminan stopwords, puntuacion y ruido.
2. **Refinamiento por similitud semantica:** cada respuesta se compara contra un conjunto de conceptos definidos en la configuracion (por ejemplo: confianza, apoyo, tema en comun, actividad cultural), seleccionando las etiquetas mas cercanas por umbral.