

Recolección de comentarios desde Google Places API

Para esta parte del proyecto se trabajó con una base de datos previa de negocios, la cual ya contenía información general de cada establecimiento, como el nombre del negocio, su categoría, ubicación, calificación general, número total de valoraciones y, principalmente, el `place_id`. Este último dato fue fundamental, porque permitió consultar directamente cada negocio en la API oficial de Google Places sin tener que buscarlo manualmente por nombre.

El archivo inicial contenía columnas como `place_id`, `name`, `rating`, `user_ratings_total`, `vicinity`, `latitud`, `longitud`, `business_status`, entre otras. A partir de esta información se realizó la extracción de comentarios utilizando Python, principalmente con librerías como `pandas`, `requests` y `time`.

Primero se hicieron pruebas con una cantidad pequeña de negocios para verificar que la conexión con la API funcionara correctamente y que los datos se estuvieran guardando con la estructura esperada. Después de comprobar que el proceso sí devolvía comentarios, se continuó con bloques más grandes de negocios. Esto se hizo así para poder revisar los resultados por partes, evitar perder avances y detectar posibles errores durante la ejecución.

La consulta se realizó mediante el servicio de Place Details de Google Places API. Para cada negocio, el script tomaba el `place_id` del archivo original y hacía una solicitud a Google para obtener los comentarios disponibles. Es importante mencionar que Google Places devuelve un número limitado de comentarios por negocio, por lo que se guardaron hasta cinco reseñas por establecimiento cuando estaban disponibles.

Durante la recolección se conservaron algunos datos del archivo original para mantener la trazabilidad de cada comentario. Por eso, en el archivo de salida se incluyeron columnas como `source_row`, `place_id`, `name`, `rating`, `user_ratings_total`, `review_text` y `review_rating`.

La columna `source_row` se agregó para identificar la fila original del negocio dentro del archivo base. Esto fue útil porque cada negocio podía generar varias filas en el archivo de salida, ya que cada comentario se guardó como una fila independiente. De esta forma, aunque un negocio tuviera varios comentarios, todos podían relacionarse con su registro original.

El archivo resultante se fue guardando en formato CSV. Para no perder los resultados anteriores, las nuevas tandas se agregaron al final del mismo archivo, sin sobrescribir lo que ya se había recolectado. Esto permitió construir progresivamente una base más grande de comentarios.

También se incluyó manejo de errores en el proceso. Si algún negocio no tenía comentarios, si el `place_id` no era válido, si la API no respondía correctamente o si ocurría un `timeout`, el programa no se detenía por completo. En esos casos, simplemente se registraba el problema y se continuaba con el siguiente negocio. Además, se agregó una pausa entre solicitudes para evitar hacer demasiadas peticiones seguidas a la API.

Un punto importante fue que se configuró la consulta para dar preferencia a comentarios en español, ya que el análisis del proyecto se enfoca en negocios ubicados en México. Aunque

no se revisó manualmente cada comentario uno por uno, durante la revisión general de los datos se observó que la mayoría de los comentarios obtenidos estaban en español, lo cual facilitó las etapas posteriores de limpieza y análisis textual.

En resumen, la recolección de datos consistió en tomar los negocios ya existentes en el archivo original, consultar sus comentarios mediante el `place_id` usando Google Places API y guardar los resultados en un nuevo archivo CSV. Cada comentario quedó registrado como una fila independiente, conservando información básica del negocio para poder relacionarlo con su origen y facilitar el análisis posterior.

Limpieza y preparación de los datos de reviews

Después de la recolección, se trabajó con el archivo `reviews_output.csv`, el cual contenía los comentarios obtenidos mediante la API oficial de Google Places. Cada fila del archivo representa una reseña individual asociada a un negocio específico. El objetivo de esta etapa no fue clasificar los comentarios ni hacer todavía un análisis profundo de sentimiento, sino preparar el conjunto de datos para que pudiera utilizarse posteriormente en análisis de texto, modelos de lenguaje, clustering o cualquier otra técnica relacionada con procesamiento de lenguaje natural.

El archivo original contenía 62,020 filas y 7 columnas. Antes de realizar la limpieza, se revisó la estructura general del dataset, los valores nulos, los comentarios vacíos, los duplicados y la cantidad de negocios únicos. Esta revisión inicial permitió identificar que existían 8,722 reviews vacíos o nulos, los cuales no aportaban información textual útil para las siguientes etapas del proyecto. Después de eliminar estos registros, el dataset quedó con 53,298 filas. Posteriormente, se eliminaron 18 duplicados exactos, por lo que el archivo final quedó con 53,280 reviews limpios. En total, el archivo limpio contiene comentarios asociados a 13,925 negocios únicos.

Durante la limpieza se conservó la columna original `review_text` sin modificaciones, con el fin de mantener la trazabilidad sobre el comentario original obtenido desde Google Places. En lugar de sobrescribir el texto original, se creó una nueva columna llamada `review_text_clean`, donde se almacenó una versión limpia del comentario. Esta decisión fue importante porque permite comparar el texto original con el texto procesado y evita perder información que podría ser útil más adelante.

La limpieza aplicada al texto fue ligera y conservadora. Se convirtieron los comentarios a minúsculas, se eliminaron espacios innecesarios, saltos de línea, tabulaciones, caracteres invisibles y signos repetidos excesivos. Por ejemplo, secuencias como `!!!!` o `????` se redujeron a un solo signo. Sin embargo, no se eliminaron completamente los signos de admiración o interrogación, ya que pueden aportar información sobre la intención, emoción o intensidad del comentario.

También se decidió no eliminar palabras cortas ni comentarios breves. Comentarios como “ok”, “bueno”, “malo”, “excelente” o “regular” pueden parecer simples, pero siguen aportando información sobre la percepción del usuario. Por esta razón, los comentarios

cortos se conservaron y únicamente se marcaron mediante una columna de control llamada `is_short_review`. En total, se identificaron 3,374 reviews cortos, usando como criterio un máximo de tres palabras.

En cuanto a los emojis, se decidió convertirlos a texto en lugar de eliminarlos. Esta decisión se tomó porque los emojis pueden aportar información emocional dentro de los comentarios. Por ejemplo, un emoji de felicidad, enojo o tristeza puede complementar el significado del texto escrito. Para esta versión de la limpieza, los emojis fueron convertidos a nombres de texto usando la librería `emoji`. En total, se detectaron 6,442 reviews con emojis y aproximadamente 12,253 emojis en todo el dataset.

Además, se generaron columnas adicionales para facilitar el control de calidad y el análisis posterior. Entre ellas se encuentran `text_length`, que indica la longitud del comentario limpio; `word_count`, que cuenta el número de palabras; `has_emoji`, que identifica si el comentario original contenía emojis; `emoji_count`, que registra el número aproximado de emojis; `has_numbers`, que indica si el comentario contiene números; `has_url`, que identifica la presencia de enlaces; y `clean_text_is_empty`, que permite saber si un comentario quedó vacío después de la limpieza.

Un resultado importante de esta etapa fue que ningún texto quedó vacío después del proceso de limpieza. Esto indica que la limpieza no eliminó información textual útil de los comentarios que sí habían pasado el primer filtro. También se detectó solamente un comentario con URL y 10,535 reviews con números, lo cual puede deberse a precios, fechas, cantidades, tiempos de espera u otros datos mencionados dentro de las reseñas.

El archivo final generado fue `reviews_clean_emoji_text.csv`. Este archivo contiene 53,280 filas y 18 columnas. También se generó un reporte automático llamado `cleaning_report_emoji_text.txt`, donde se registraron los resultados de la limpieza, la configuración utilizada y los conteos principales del proceso. Este reporte sirve como evidencia de trazabilidad y permite verificar qué transformaciones se aplicaron al dataset.

Las columnas finales del archivo limpio fueron: `review_id`, `source_row`, `place_id`, `name`, `rating`, `user_ratings_total`, `review_rating`, `review_text`, `review_text_clean`, `has_review_text`, `text_length`, `word_count`, `is_short_review`, `clean_text_is_empty`, `has_url`, `has_numbers`, `has_emoji` y `emoji_count`.

En resumen, la limpieza permitió eliminar registros sin texto, quitar duplicados exactos, conservar los comentarios originales, generar una versión limpia del texto y agregar variables de control de calidad. El dataset resultante quedó preparado para las siguientes fases del proyecto, como análisis exploratorio, análisis de sentimiento, generación de embeddings, reducción de dimensionalidad o integración con el dataset principal de negocios.

Análisis de sentimiento con modelo Transformer

Después de terminar la limpieza de los comentarios, se realizó una etapa adicional de análisis de sentimiento. El objetivo de esta parte fue aprovechar el texto de las reseñas para

obtener una variable más relacionada con la percepción de los clientes, ya que la calificación numérica de Google no siempre explica por completo la experiencia descrita en los comentarios.

Para este análisis se utilizó un modelo Transformer previamente entrenado para clasificación de sentimiento en español ("pysentimiento/robertuito-sentiment-analysis"). Es importante aclarar que no se entrenó un modelo desde cero, sino que se usó un modelo ya entrenado para clasificar cada comentario limpio. Esto permitió procesar las reseñas de manera automática y asignarles una etiqueta de sentimiento.

El análisis se aplicó sobre la columna `review_text_clean`, que contiene la versión limpia de cada comentario. Esta columna ya no tenía saltos de línea, espacios innecesarios ni caracteres invisibles, pero conservaba el contenido principal de la reseña. De esta forma, el modelo pudo trabajar con un texto más ordenado sin modificar el comentario original guardado en `review_text`.

El modelo clasificó cada review en una de tres categorías:

- POS: comentario positivo.
- NEG: comentario negativo.
- NEU: comentario neutral.

Además de la etiqueta, el modelo generó un valor llamado `sentiment_score`, que representa el nivel de confianza del modelo respecto a la clasificación asignada. Por ejemplo, si una reseña fue clasificada como NEG con un score alto, eso no significa que el comentario sea positivo, sino que el modelo tiene alta confianza en que el comentario pertenece a la clase negativa.

También se creó una variable numérica llamada `sentiment_numeric`, con el fin de facilitar análisis posteriores. Para esta variable se usó la siguiente codificación:

- POS = 1
- NEU = 0
- NEG = -1

Esto permite resumir el sentimiento de las reseñas de forma cuantitativa y después calcular promedios por negocio, categoría o zona.

En total, se analizaron 53,280 reviews. De acuerdo con los resultados obtenidos, 34,893 comentarios fueron clasificados como positivos, 13,440 como negativos y 4,947 como neutrales. En términos porcentuales, esto representa aproximadamente 65.49% de comentarios positivos, 25.23% negativos y 9.28% neutrales.

El promedio general de sentimiento numérico fue de 0.4026. Este valor indica que, en general, las reseñas tienen una tendencia positiva, aunque también existe una proporción importante de comentarios negativos. Esto es útil para el proyecto porque permite

complementar la calificación general de los negocios con una lectura más directa de la opinión escrita por los usuarios.

Como resultado de esta etapa se generaron dos archivos:

- reviews_with_transformer_sentiment.csv
- reviews_sentiment_only.csv

El primer archivo conserva todas las columnas del dataset limpio, agregando las nuevas columnas del análisis de sentimiento. El segundo archivo es una versión más reducida, pensada para trabajar de forma más práctica con las variables principales. Las columnas guardadas en esta versión fueron: review_id, place_id, name, review_rating, review_text, review_text_clean, text_length, word_count, has_emoji, emoji_count, sentiment_label, sentiment_score y sentiment_numeric.

El archivo más útil para las siguientes etapas del proyecto es reviews_sentiment_only.csv, ya que contiene la información necesaria para relacionar cada comentario con su negocio mediante place_id, además de incluir tanto el texto original como el texto limpio y el resultado del modelo de sentimiento.