

Universidad Nacional Autónoma de México
Facultad de Estudios Superiores Acatlán
Matemáticas Aplicadas y Computación
Minería de Datos
Práctica de Análisis Exploratorio

Integrantes del equipo

Alvarado Martínez Miguel Eduardo

Bustos Antonio José Arturo

Estrada Romero Melisa Edith

Soria Cabrera Andrés

Sosa Pérez Dariana Montserrat

12 de Abril de 2026

Análisis y Metodología de Preprocesamiento

El presente análisis se fundamenta en la necesidad de identificar patrones de comportamiento interpersonal dentro de una muestra de estudiantes de la licenciatura en Matemáticas Aplicadas y Computación. Debido a la naturaleza del conjunto de datos, el cual cuenta con un volumen limitado de registros (14 observaciones), la fase de preprocesamiento fue crítica para asegurar la validez de los resultados. Se tomó la decisión técnica de entrenar los modelos de agrupación exclusivamente con las variables numéricas y de escala, evitando la creación de variables indicadoras mediante One-Hot Encoding para los campos de texto libre. Esta elección responde a la necesidad de mantener un equilibrio entre el número de características y el número de registros, previniendo así la pérdida de significancia estadística que ocurre cuando las dimensiones superan a las muestras.

Para garantizar que el algoritmo de agrupamiento no se viera sesgado por las diferentes magnitudes de las variables, como las escalas de frecuencia versus el tiempo de soltería, se implementó una estandarización mediante el método de puntuación Z (Z-score). Este proceso normalizó todas las características a una media de cero y una desviación estándar de uno, permitiendo que las distancias matemáticas calculadas por los algoritmos fueran equitativas. Finalmente, para facilitar la interpretación y comunicación de los resultados, se aplicó un Análisis de Componentes Principales (PCA) que redujo la dimensionalidad del problema a dos componentes principales, permitiendo visualizar la formación de los grupos en un plano bidimensional sin perder la esencia de la varianza original de los datos.

Algoritmos de Agrupamiento

En esta práctica se evaluaron cuatro enfoques distintos de aprendizaje no supervisado para contrastar su efectividad en la segmentación de perfiles. El primero es el algoritmo K-Means, el cual opera bajo un esquema de partición basado en centroides, buscando minimizar la distancia interna de los puntos respecto al centro de su clúster asignado. Es un método eficiente para encontrar grupos con formas compactas y bien definidas, siempre que se determine correctamente el valor inicial de grupos a buscar. El segundo método es el Agrupamiento Jerárquico Aglomerativo, el cual utiliza una estrategia ascendente donde cada registro comienza como su propio grupo y se van fusionando sucesivamente según su similitud, permitiendo entender la estructura de relaciones de forma multinivel.

Como parte de la validación del modelo principal, se implementó el algoritmo de **Agrupamiento Jerárquico Aglomerativo** utilizando la métrica euclidiana y el método de vinculación de Ward. Esta técnica permitió visualizar la estructura de los

datos a través de un dendrograma, el cual facilitó la observación de cómo se fusionan los individuos en clústeres según su similitud de varianza. Al establecer un corte en el dendrograma para obtener tres grupos, se confirmó una consistencia total con los resultados obtenidos previamente en K-Means. Esta concordancia entre dos algoritmos de distinta naturaleza (particional y jerárquico) fortalece la robustez de la segmentación, demostrando que la división de la muestra en tres perfiles no es un artefacto de un solo método, sino una estructura natural presente en los datos de los estudiantes.

Por otro lado, se aplicó el algoritmo **DBSCAN** para obtener una perspectiva basada exclusivamente en la densidad espacial de los registros. Para evitar la selección arbitraria de parámetros, se utilizó una gráfica de k-distancia mediante el método de *Nearest Neighbors*, identificando un radio de búsqueda óptimo (eps) de 2.5. A diferencia de los modelos anteriores, DBSCAN identificó dos clústeres densos y clasificó a dos individuos como ruido o valores atípicos (*outliers*). Este hallazgo es de alto valor para el proyecto, ya que permite aislar perfiles con comportamientos significativamente distintos al resto de la muestra, los cuales requieren una atención diferenciada en nuestra propuesta de mercado. La capacidad de DBSCAN para ignorar el ruido asegura que los grupos principales detectados sean verdaderamente cohesivos y no se vean distorsionados por casos excepcionales.

Para complementar nuestro análisis y explorar una técnica que no dependa de la definición previa del número de grupos (k), se implementó el algoritmo de Propagación de Afinidad. A diferencia de K-Means, este modelo opera mediante el intercambio de mensajes entre los puntos de datos hasta que emerge un conjunto de nodos ejemplares o "arquetipos" que mejor representan a su vecindario.

Al procesar nuestra muestra de 14 estudiantes, el algoritmo convergió identificando de manera automática **4 clústeres** (arquetipos estudiantiles). El modelo arrojó un Coeficiente de Silueta de 0.263, lo cual es matemáticamente congruente con los resultados obtenidos en las fases de optimización previas. Mediante una reducción de dimensionalidad con PCA a dos componentes, fue posible visualizar la formación de las agrupaciones en un esquema de estrella, donde cada estudiante periférico se conecta directamente con el caso arquetípico de su segmento. Aunque este algoritmo sugiere una división en 4 grupos, lo cual confirma la alta dispersión de personalidades en la muestra, la decisión del equipo se mantiene en conservar los 3 clústeres de K-Means como el estándar operativo para la estrategia de negocio por motivos de viabilidad en la implementación.

Perfilamiento de los Clústeres y Hallazgos

Tras la ejecución del modelo óptimo con tres clústeres, se identificaron perfiles diferenciados que reflejan la diversidad de la muestra. El clúster mayoritario, que agrupa a nueve individuos, representa el perfil estándar de integración social dentro de la carrera, mostrando niveles equilibrados en comunicación y proactividad. Por otro lado, se identificó un segmento nicho de dos personas que se caracteriza por una marcada preferencia hacia actividades de bajo volumen social y una mayor valoración del tiempo de introspección, lo que sugiere un perfil de independencia emocional. El tercer grupo, compuesto por tres personas, destaca por una alta energía interpersonal y una iniciativa constante para establecer nuevos vínculos, posicionándose como los perfiles más proactivos del conjunto de datos.

Propuesta de Mercado y Aplicación de Negocio

Con base en la segmentación obtenida, se propone la implementación de una plataforma de vinculación académica y recreativa denominada "MAC-Connect". Para el grupo mayoritario, la estrategia de negocio se centrará en la creación de eventos de integración a gran escala y redes de estudio colaborativo que aprovechen su disposición social natural. Para el segmento con tendencia a la introspección, la propuesta de valor consistirá en servicios de mentoría personalizada y espacios de trabajo individualizados que respeten su necesidad de seguridad emocional y baja estimulación grupal. Finalmente, para el segmento de alta proactividad, se sugiere un programa de embajadores estudiantiles que lideren iniciativas de vinculación externa y proyectos deportivos, canalizando su energía interpersonal en actividades que beneficien la cohesión de toda la comunidad estudiantil.

Interpretación Analítica de la Optimización (GridSearchCV vs. Análisis Visual)

Tras ejecutar la búsqueda exhaustiva (GridSearchCV) y la búsqueda aleatoria (RandomizedSearchCV), los algoritmos sugirieron la formación de 5 y 4 clústeres respectivamente, ya que matemáticamente esto minimiza la inercia (la distancia entre los puntos y su centroide).

Sin embargo, tomamos la decisión técnica de mantener el modelo final en $k=3$. La justificación radica en el tamaño de nuestra muestra ($n=14$). Si creamos 4 o 5 grupos para tan pocos registros, llegaríamos a un claro sobreajuste (*overfitting*), generando subgrupos aislados de una sola persona que carecerían de valor

estadístico y de aplicabilidad real para nuestra propuesta de mercado. Por lo tanto, el modelo de 3 clústeres nos proporciona el equilibrio ideal entre coherencia matemática y viabilidad de negocio.

Conclusión

EL implementación de múltiples algoritmos de aprendizaje no supervisado abarcando enfoques particionales, jerárquicos, de densidad y de afinidad, ha permitido validar la robustez de los perfiles identificados. La convergencia de resultados entre metodologías de distinta naturaleza confirma que los segmentos detectados representan estructuras subyacentes genuinas en la población estudiantil, y no meros artefactos algorítmicos. El priorizar la interpretabilidad y el sentido de negocio sobre la optimización matemática asegura que la segmentación propuesta sea tanto estadísticamente válida como operativamente útil para el desarrollo de estrategias de integración dentro de la licenciatura en Matemáticas Aplicadas y Computación.